GAP SEARCH JURNAL

Pemetaan kemiripan dan pengelompokan kegiatan riset berbasis teks dan graf

1. Karakteristik data TA (acuan pemilihan jurnal)

Aspek	Kondisi data kegiatan_2025.csv
Unit analisis	Kegiatan riset (node pada graf); 38 kegiatan dari PRSDI (33) dan PRGI (5)
Bentuk teks	Judul kegiatan, rata-rata 14 kata (4 sampai 23 kata); campuran bahasa Indonesia dan Inggris; banyak frasa baku (“Kegiatan Riset Mandiri tentang…”)
Hasil awal	TF-IDF + K-Means: silhouette 0,01 sampai 0,06; kemiripan cosine antarpasangan umumnya di bawah 0,2
Label	Kelompok Riset bersifat administratif dan tidak selalu sesuai topik; belum ada label topik yang sahih
Tujuan lanjutan	Graf kemiripan, deteksi komunitas (mis. Louvain), pembanding K-Means

2. Penyaringan jurnal yang diunggah

No	Jurnal	Alasan relevansi / ketidakcocokan	Keputusan
1	Mikhina & Trifalenkov (2018) Text clustering as graph community detection Procedia Comput. Sci. 123:271–277	Persis pada alur yang akan kamu pakai: TF-IDF, cosine similarity, graf berbobot, pembuangan sisi tidak signifikan, lalu komunitas. Skala koleksi kecil (12 sampai 16 dokumen).	DIPILIH
2	Subakti, Murfi & Hariadi (2022) The performance of BERT as data representation of text clustering J. Big Data 9:15	Membandingkan TF-IDF dan BERT pada clustering teks dengan K-Means sebagai salah satu algoritma, termasuk dokumen dipotong 25 token. Menjawab RQ1 (representasi).	DIPILIH
3	Liu & Barahona (2020) Graph-based data clustering via multiscale community detection Appl. Netw. Sci. 5:3	Membahas cara membangun graf dari data (kNN, CkNN, dan lainnya), deteksi komunitas multiskala tanpa menetapkan jumlah cluster, dan perbandingan dengan K-Means. Data berupa vektor numerik, bukan teks.	DIPILIH
4	Mu dkk. (2022) ClusTop: clustering-based topic model with word networks and word embeddings J. Big Data 9:38	Teks pendek (tweet) dan deteksi komunitas Louvain dengan jumlah topik otomatis. Namun node-nya kata, bukan dokumen, dan datanya puluhan ribu tweet.	Pendukung
5	Sieranoja & Fränti (2022) Adapting k-means for graph clustering Knowl. Inf. Syst. 64:115–142	Pengelompokan graf dengan jumlah cluster ditentukan pengguna, dan membahas bahwa label buatan manusia belum tentu mencerminkan struktur sebenarnya. Data berupa graf kNN numerik dan jaringan penyakit.	Pendukung

No	Jurnal	Alasan relevansi / ketidakcocokan	Keputusan
6	Wellem & Nataliani (2017) Clustering Graf dengan Algoritma Rantai Markov Jurnal Teknologi Informasi-Aiti 14(2)	Algoritma Markov Clustering pada graf lalu lintas jaringan (HTTP). Tidak memakai teks dan tidak ada evaluasi terhadap label.	Tidak dipilih (hanya rujukan MCL)

Catatan: jurnal nomor 4 dan 5 dipakai sebagai penguat argumen (lihat kolom referensi pendukung pada bagian 4), bukan baris utama matriks.

3. Matriks literatur (3 jurnal utama)

No	Referensi	Data / domain	Representasi dan konstruksi graf	Metode dan evaluasi	Temuan utama	Keterbatasan / celah
1	Mikhina & Trifalenkov (2018) Text clustering as graph community detection. Procedia Computer Science 123, 271–277. DOI 10.1016/j.procs.2018.01.042	Artikel berita berbahasa Rusia. Tiga koleksi kecil: 16 dokumen (4 cluster), 16 dokumen (15+1), 12 dokumen (1 pasang + 10 tunggal). Label benar dibuat manual.	Stopword, stemming minimal, TF-IDF, bigram signifikan. Cosine similarity menjadi bobot sisi graf. Sisi tidak signifikan dibuang per dokumen dengan ambang r_i (perubahan relatif terbesar pada kemiripan terurut), lalu bobot dirata-ratakan dua arah.	Agglomerative hierarchical pada graf; berhenti saat perubahan modularitas (ΔQ) negatif, sehingga jumlah cluster otomatis. Evaluasi: F1 rata-rata terhadap label manual.	Metode tanpa parameter dari pengguna; hasil identik dengan label manual pada dua koleksi (F1 = 1) dan F1 = 0,86 pada koleksi “satu pengecualian”. Hierarki cluster menunjukkan kedekatan antarcluster.	Hanya 3 koleksi dan paling banyak 16 dokumen. Hanya TF-IDF; tidak ada representasi semantik (embedding). Tidak ada pembanding metode lain dalam artikel. Teks berbahasa Rusia, bukan judul pendek atau dwibahasa.
2	Subakti, Murfi & Hariadi (2022) The performance of BERT as data representation of text clustering. Journal of Big Data 9:15. DOI 10.1186/s40537-022-00564-9	AG News (4 kelas, 4.000), Yahoo! Answers (10 kelas, 10.000), Reuters R2 (2 kelas, 5.859). Teks berbahasa Inggris; label kelas tersedia.	TF-IDF vs BERT-base uncased (fitur lapisan ke-11). Dokumen dipotong atau di-padding menjadi 25 token. Max/mean pooling dan 4 jenis normalisasi.	K-Means, EFCM (fuzzy c-means), DEC, IDEC. Evaluasi: ACC, NMI, ARI terhadap label; 50 pengulangan.	BERT mengungguli TF-IDF pada 28 dari 36 metrik; pada R2, TF-IDF sedikit lebih baik atau sebanding. Kombinasi pooling dan normalisasi terbaik bergantung pada algoritma; min–max normalization hasilnya paling buruk.	Bahasa Inggris dan data besar berlabel. Tidak ada algoritma berbasis graf. Tidak membahas bahasa Indonesia, teks campuran bahasa, atau data puluhan dokumen. Model BERT berbahasa Inggris (uncased).
3	Liu & Barahona (2020) Graph-based data clustering via multiscale community detection. Applied Network Science 5:3. DOI 10.1007/s41109-019-0248-7	11 dataset UCI (106 sampai 2.310 sampel; 4 sampai 60 fitur numerik) dengan label benar. Bukan data teks.	Jarak Euclidean; graf dibangun dengan ε-ball, kNN, CkNN, PMST, RMST. Graf CkNN ($k \geq 7$) memberi hasil rata-rata terbaik.	Markov Stability (varian Louvain) memindai skala (Markov time); jumlah cluster dicari dari partisi yang robust. Pembanding: K-Means, GMM, hierarchical, dua spectral clustering. Evaluasi: NMI dan ARI.	Rata-rata NMI 0,586 dan ARI 0,540 ($c = c^*$), tertinggi di antara metode yang dibandingkan. Tanpa menetapkan jumlah cluster, rata-rata NMI 0,602 dan ARI 0,539. Pemindaian skala mengurangi sensitivitas terhadap parameter pembangunan graf.	Data numerik dan jarak Euclidean; belum diuji pada teks atau vektor embedding. CkNN mensyaratkan jarak berupa metrik, perlu dicek untuk cosine. Memilih partisi robust masih dilakukan manual; penulis menyebut proses statistik otomatis sebagai pekerjaan lanjutan.

Referensi pendukung (dari jurnal 4 dan 5)

- Mu dkk. (2022), J. Big Data 9:38: komunitas Louvain pada jaringan kata untuk teks pendek dengan jumlah topik otomatis. Infomap dan Label Propagation disebut menghasilkan banyak komunitas kecil sehingga tidak dipilih. Pekerjaan lanjutan yang disebut: kebutuhan label ground truth beranotasi sebagai tantangan evaluasi.
- Sieranoja & Fränti (2022), KAIS 64:115–142: pada jaringan penyakit, label kategori buatan manusia belum tentu mencerminkan struktur sebenarnya, dan tujuan clustering adalah menemukan informasi baru. Mendukung argumen bahwa Kelompok Riset tidak cocok sebagai satu-satunya ground truth.

4. Sintesis celah (gap)

Kolom “Temuan dalam 3 jurnal” hanya merangkum isi jurnal yang dibaca. Kolom “Status” menunjukkan seberapa kuat dukungannya.

Dimensi	Temuan dalam 3 jurnal	Kondisi data TA	Celah yang dapat diangkat	Status
1. Teks pendek dan data sedikit	Mikhina & Trifalenkov (2018): hanya 12–16 dokumen (artikel berita), TF-IDF. Subakti, Murfi & Hariadi (2022): judul dipotong 25 token, tetapi dengan ribuan sampel.	38 judul pendek (rata-rata 14 kata).	Belum ada kajian dalam tiga jurnal ini yang memetakan judul riset pendek dalam jumlah puluhan dengan graf kemiripan.	Didukung 2 jurnal; verifikasi lanjutan
2. Representasi × graf	Mikhina & Trifalenkov (2018): graf dari TF-IDF saja. Subakti, Murfi & Hariadi (2022): TF-IDF vs BERT hanya pada algoritma non-graf. Liu & Barahona (2020): graf dari vektor numerik.	TF-IDF gagal menghubungkan istilah setara (mis. “citra satelit” dan “penginderaan jauh”).	Pengaruh representasi (TF-IDF vs embedding multibahasa) terhadap kualitas graf kemiripan dan komunitas yang terbentuk.	Didukung 3 jurnal
3. Konstruksi graf untuk teks	Mikhina & Trifalenkov (2018): ambang adaptif per dokumen (r_i). Liu & Barahona (2020): CkNN, kNN, RMST, dan lainnya pada data numerik.	Matriks kemiripan padat dan bernilai kecil; banyak node hampir terisolasi.	Perbandingan metode penyaringan sisi (ambang, kNN, CkNN, r_i) pada graf kemiripan teks.	Didukung 2 jurnal
4. Bahasa	Subakti, Murfi & Hariadi (2022): data Inggris, BERT-base uncased. Mikhina & Trifalenkov (2018): teks Rusia.	Judul campuran Indonesia–Inggris.	Evaluasi pada teks Indonesia–Inggris bercampur belum terlihat pada ketiga jurnal.	Didukung 2 jurnal; cari studi bahasa Indonesia
5. Evaluasi tanpa label sahih	Mikhina & Trifalenkov (2018): label manual. Subakti, Murfi & Hariadi (2022): label kelas. Liu & Barahona (2020): label UCI. Mu dkk. dan Sieranoja & Fränti menyinggung masalah label.	Kelompok Riset administratif; belum ada label topik.	Rancangan evaluasi dengan label topik manual (dua penilai) plus penilaian kualitatif, bukan hanya silhouette atau label administratif.	Kuat (5 jurnal menyentuh)
6. Jumlah cluster dan skala	Mikhina & Trifalenkov (2018): jumlah cluster otomatis lewat modularitas. Liu & Barahona (2020): pemindaian multiskala, jumlah cluster tanpa input.	Jumlah tema sebenarnya tidak diketahui.	Menguji apakah penentuan jumlah cluster otomatis stabil pada data kecil dan teks pendek.	Didukung 2 jurnal
7. Tema tumpang tindih	Ketiga jurnal menghasilkan partisi terpisah (tidak tumpang tindih) pada eksperimen yang dilaporkan.	Kegiatan bisa masuk dua tema (metode × domain).	Pendekatan komunitas bertumpang tindih atau soft assignment untuk pemetaan riset.	Hipotesis lemah; perlu dicari literatur overlapping community
8. Domain aplikasi	Tiga jurnal tidak membahas portofolio kegiatan riset lembaga. Mu dkk. menyebut penelitian lain yang	Kegiatan riset BRIN lintas pusat riset.	Pemetaan tumpang tindih tema riset lintas kelompok di lembaga riset Indonesia.	Perlu verifikasi dengan pencarian lanjutan

Dimensi	Temuan dalam 3 jurnal	Kondisi data TA	Celah yang dapat diangkat	Status
	memetakan tema riset HCI dari kata kunci artikel (rujukan [12] di Mu dkk.).			

5. Draf rumusan gap dan RQ

Komponen	Draf (sesuaikan dengan arahan pembimbing)
Apa yang sudah dilakukan	Mikhina & Trifalenkov (2018) menunjukkan teks dapat dikelompokkan sebagai komunitas pada graf kemiripan TF-IDF, termasuk pada koleksi kecil. Subakti, Murfi & Hariadi (2022) menunjukkan representasi BERT umumnya lebih baik daripada TF-IDF pada clustering teks. Liu & Barahona (2020) menunjukkan konstruksi graf dan skala resolusi memengaruhi hasil clustering berbasis komunitas.
Keterbatasan	Ketiganya diuji pada data berlabel (berita, kelas, UCI), dengan bahasa Inggris atau Rusia, atau vektor numerik. Tidak ada yang menggabungkan representasi semantik, konstruksi graf, dan deteksi komunitas pada judul kegiatan riset pendek, dwibahasa, dan berjumlah puluhan.
Posisi penelitian	Penelitian ini membandingkan representasi TF-IDF dan embedding pada graf kemiripan kegiatan riset, menguji beberapa penyaringan sisi, mendeteksi komunitas, dan membandingkannya dengan K-Means menggunakan label topik manual sebagai ground truth.
RQ (usulan revisi)	RQ1: Representasi mana (TF-IDF atau embedding multibahasa) yang menghasilkan graf kemiripan paling sesuai dengan label topik manual? RQ2: Metode penyaringan sisi mana yang menghasilkan komunitas paling stabil pada 38 kegiatan? RQ3: Apakah deteksi komunitas lebih baik daripada K-Means pada data ini, dan seberapa sejalan hasilnya dengan Kelompok Riset?

Daftar referensi (tiga jurnal utama)

- Mikhina, E. K., & Trifalenkov, V. I. (2018). Text clustering as graph community detection. Procedia Computer Science, 123, 271–277. https://doi.org/10.1016/j.procs.2018.01.042
- Subakti, A., Murfi, H., & Hariadi, N. (2022). The performance of BERT as data representation of text clustering. Journal of Big Data, 9, 15. https://doi.org/10.1186/s40537-022-00564-9
- Liu, Z., & Barahona, M. (2020). Graph-based data clustering via multiscale community detection. Applied Network Science, 5, 3. https://doi.org/10.1007/s41109-019-0248-7